

FitLife Analytics

Análisis de abandono de socios y estrategias de retención

Elemento	Detalle
Proyecto	Proyecto Integrador Final - Bootcamp Data Analytics
Autora	Carmen García Mateo
Fecha	Junio 2026
Herramientas	Python, SQL, Power BI, GitHub
Técnica analítica	Regresión logística interpretativa

1. Resumen ejecutivo

FitLife es un proyecto de analítica de datos orientado a entender el abandono de socios en un gimnasio y a proponer acciones de retención basadas en evidencia. El problema de negocio se centra en identificar qué perfiles presentan mayor probabilidad de baja y cómo priorizar intervenciones para reducir el churn.

El análisis se desarrolló de principio a fin: exploración inicial del dataset, limpieza y enriquecimiento, diseño de un modelo estrella para SQL, consultas de negocio, análisis exploratorio, dashboard en Power BI y aplicación de una regresión logística para interpretar los factores asociados al abandono.

Indicador	Resultado
Socios analizados	4.000
Socios dados de baja	1.061
Tasa global de abandono	26.52 %
Vida media antes de la baja	0.99 meses
Coste estimado del abandono	52.92 mil €
Ahorro potencial si se reduce 20 %	10.58 mil €

Resultado principal: el abandono se concentra en socios con contrato mensual, baja antigüedad, menor edad y menor vinculación social o de actividad. Los socios que asisten a clases grupales, los que llegan por recomendación y los que tienen contratos de mayor duración presentan tasas de abandono claramente inferiores.

2. Introducción

La retención de clientes es una prioridad en modelos de negocio basados en suscripciones, como gimnasios y centros deportivos. En este tipo de negocio, una baja tasa de permanencia afecta directamente a los ingresos recurrentes, a la planificación comercial y al coste de adquisición de nuevos socios.

El proyecto plantea el caso de FitLife, un gimnasio que quiere transformar sus datos históricos de socios en una herramienta de análisis para entender el abandono, detectar segmentos vulnerables y diseñar acciones preventivas.

2.1 Objetivo general

Analizar el comportamiento de abandono de los socios de FitLife para identificar factores asociados al churn y proponer recomendaciones de retención accionables.

2.2 Objetivos específicos

- Medir la tasa global de abandono y su impacto económico estimado.
- Identificar los segmentos de socios con mayor riesgo de baja.
- Validar hipótesis de negocio relacionadas con contrato, antigüedad, edad, clases grupales, captación y pareja social.
- Construir una base SQL con un modelo lógico simple y consultas relevantes.
- Desarrollar un dashboard en Power BI con KPIs, filtros y visualizaciones interpretables.
- Aplicar una regresión logística para interpretar variables asociadas al abandono.

2.3 Preguntas de negocio

- ¿Qué tipo de contrato presenta mayor abandono?
- ¿En qué etapa de la relación con el gimnasio se concentra la baja?
- ¿Qué papel tienen la edad, las clases grupales y la captación por promoción?
- ¿Qué segmentos activos deberían priorizarse en campañas de retención?
- ¿Qué variables pesan más en el modelo de abandono?

3. Descripción de los datos

El dataset utilizado contiene registros de socios de un gimnasio, con variables demográficas, contractuales, de actividad, captación y abandono. El archivo original se conservó en formato CSV y se generó un dataset procesado y enriquecido para el análisis.

Elemento	Detalle
Archivo original	data/raw/gym_churn_us.csv
Archivo procesado	data/processed/gym_churn_enriquecido.csv
Registros	4.000
Columnas originales fiables	11 tras excluir 3 variables corruptas
Columnas finales enriquecidas	17
Variable objetivo	Churn: 0 = socio activo, 1 = baja

3.1 Variables principales

Grupo	Variables
Demográficas	gender, Age, Near_Location, Partner
Contrato	Contract_period, Month_to_end_contract
Actividad	Group_visits
Captación	Promo_friends, Phone
Relación con el gimnasio	Lifetime
Target	Churn
Variables enriquecidas	genero_texto, grupo_edad, tipo_contrato, nivel_compromiso, perfil_captacion, segmento_lifetime

3.2 Limitaciones iniciales

Tres variables del dataset original presentaban un problema de exportación: Avg_additional_charges_total, Avg_class_frequency_total y Avg_class_frequency_current_month aparecían como texto con múltiples puntos, sin una regla estable para reconstruir el decimal correcto. Se decidió excluirlas para evitar introducir ruido y conclusiones no fiables.

Después de excluir esas columnas aparecen 859 filas con el mismo perfil en las variables restantes. No se eliminaron porque no representan duplicados reales de socio, sino perfiles repetidos en un dataset con variables discretas y rangos limitados.

4. Preparación y limpieza

La preparación de datos se realizó en Python, principalmente con pandas. El objetivo fue conservar el máximo número de registros fiables, corregir la estructura de variables y crear campos de negocio interpretables para el EDA, SQL y Power BI.

Proceso	Decisión aplicada
Carga del CSV	Lectura con separador punto y coma.
Variables corruptas	Exclusión de las tres columnas afectadas por bug de formato.
Valores nulos	No se detectaron nulos en el dataset procesado.
Duplicados aparentes	No se eliminaron por no representar socios repetidos.
Codificación legible	Creación de etiquetas para género, contrato, edad y captación.
Segmentación	Clasificación de antigüedad: nuevo, intermedio y veterano.

4.1 Variables enriquecidas

Variable nueva	Descripción
genero_texto	Etiqueta Hombre/Mujer a partir de gender.
grupo_edad	Tramos 18-25, 26-30, 31-35 y 36-41.
tipo_contrato	Mensual, semestral o anual.
nivel_compromiso	Bajo, medio o alto según duración contractual.
perfil_captacion	Combinación entre recomendación/promoción y teléfono registrado.
segmento_lifetime	Nuevo, intermedio o veterano según antigüedad.

4.2 Resultado de limpieza

El dataset final mantiene 4.000 socios y 17 columnas. sin valores nulos. La decisión de excluir columnas corruptas favorece la trazabilidad del análisis y evita conclusiones basadas en datos no reconstruibles.

5. Base de datos SQL

Para cumplir el bloque de modelado y almacenamiento, los datos se estructuraron mediante un modelo estrella simple. El objetivo no fue crear una arquitectura compleja, sino separar dimensiones de negocio y una tabla de hechos central que permitiera consultas claras para KPIs y dashboard.

Tabla	Contenido	Filas
dim_socio	Datos demográficos y de contexto del socio	4000
dim_contrato	Tipos de contrato y nivel de compromiso	3
dim_captacion	Canal de captación y contactabilidad	4
dim_actividad	Asistencia a clases grupales	2
fact_membresia	Churn, antigüedad, contrato restante y claves	4000

5.1 Consultas principales

El script SQL incluye consultas con SELECT, JOIN, GROUP BY, subconsultas y KPIs. Las consultas se orientan a responder preguntas de negocio, no solo a demostrar sintaxis SQL.

Consulta	Propósito
Abandono por contrato	Validar si los contratos mensuales presentan mayor churn.
Abandono por captación	Comparar perfiles orgánicos y referidos.
Abandono por clases y antigüedad	Evaluar el efecto de la participación en clases.
Perfil demográfico	Cruzar edad y género con la tasa de abandono.
Segmentación de riesgo	Priorizar socios activos con reglas operativas.
KPIs de negocio	Calcular tasa global, vida media, coste y ahorro potencial.

El cálculo económico se plantea como una estimación bajo la hipótesis de 30 EUR mensuales por socio y meses restantes de contrato. Por tanto, debe interpretarse como aproximación de impacto, no como dato financiero real del dataset.

6. Análisis exploratorio

El análisis exploratorio confirma que el abandono no se distribuye de forma homogénea. Se concentra en segmentos concretos, especialmente socios nuevos, con contratos mensuales, jóvenes y con menor vinculación mediante clases o red social.

Dimensión	Hallazgo
Contrato	Mensual 42.3 %, semestral 12.5 %, anual 2.4 %.
Antigüedad	Nuevo 42.1 %, intermedio 2.6 %, veterano 0.0 %.
Edad	El grupo 18-25 alcanza 61.9 %, frente a 1.1 % en 36-41.
Clases grupales	Sin clases 33.0 %, con clases 17.3 %.
Pareja socia	Sin pareja socia 33.3 %, con pareja socia 19.4 %.




Figura 1. Tasa de abandono por tipo de contrato.




Figura 2. Tasa de abandono por antigüedad del socio.

6.1 Factores de vinculación

Las variables relacionadas con compromiso y vinculación muestran diferencias relevantes. Las clases grupales y la presencia de una pareja socia funcionan como señales de mayor conexión con el gimnasio.




Figura 3. Tasa de abandono según asistencia a clases grupales.




Figura 4. Tasa de abandono según pareja socia.

6.2 Edad y captación

El abandono cae de forma clara a medida que aumenta la edad. En captación, los perfiles referidos presentan menor tasa de abandono que los perfiles orgánicos, lo que sugiere que la recomendación social puede aumentar la calidad o la estabilidad de la captación.




Figura 5. Tasa de abandono por grupo de edad.




Figura 6. Tasa de abandono por perfil de captación.

7. Dashboard en Power BI

El dashboard se diseñó en Power BI para facilitar la interpretación de resultados y convertir el análisis en una herramienta de decisión. El archivo contiene tres páginas principales: Resumen ejecutivo, Factores de riesgo y Recomendaciones.

Página	Objetivo	Contenido principal
Resumen ejecutivo	Dar visión global del problema.	KPIs, abandono por contrato y abandono por antigüedad.
Factores de riesgo	Comparar segmentos vulnerables.	Edad, contrato, captación, clases grupales y pareja socia.
Recomendaciones	Priorizar acciones.	Coefficientes del modelo y segmentación de socios activos por riesgo.

7.1 KPIs utilizados

- Total de socios: 4.000.
- Tasa global de abandono: 26.52 %.
- Vida media antes de baja: 0.99 meses.
- Coste estimado de abandono: 52.92 mil EUR.
- Ahorro potencial si se reduce el abandono un 20 %: 10.58 mil EUR.
- Socios activos priorizados: 2.939. distribuidos en 599 de riesgo alto. 1481 de riesgo medio y 859 de riesgo bajo.




Figura 7. Vista de resumen ejecutivo del dashboard.

7.2 Interpretación del dashboard

La página de Factores de riesgo permite comparar grupos de socios y detectar dónde se concentra el abandono. La visualización por pareja socia se plantea como comparación de tasas y no como proporción de un total, lo que mejora la lectura metodológica. La página de Recomendaciones conecta los resultados del modelo con una priorización operativa.




Figura 8. Vista analítica de factores de riesgo a partir de los datos del dashboard.




Figura 9. Vista de recomendaciones y priorización de socios activos.

8. Técnica analítica aplicada: regresión logística

Se aplicó una regresión logística supervisada para estimar la probabilidad de abandono y, sobre todo, interpretar el sentido y peso relativo de las variables. La elección del modelo prioriza interpretabilidad, coherente con el objetivo del proyecto y con el criterio de evaluación del integrador.

8.1 Variables utilizadas

Tipo	Variables
Incluidas	gender, Near_Location, Partner, Promo_friends, Phone, Contract_period, Group_visits, Age
Excluidas por riesgo de leakage	Lifetime, Month_to_end_contract, segmento_lifetime
Variable objetivo	Churn

Lifetime y Month_to_end_contract se excluyen del modelo predictivo porque están muy cerca del evento de abandono y podrían introducir fuga de información. Sin embargo, sí se usan en la segmentación operativa de socios activos como reglas de negocio observables para priorizar acciones.

Métrica	Resultado
Train/Test split	80 % entrenamiento / 20 % prueba, con estratificación
Accuracy	0.805
ROC AUC	0.871
Recall clase Baja	0.467
Precision clase Baja	0.697




Figura 10. Coeficientes de la regresión logística.

8.2 Resultados e interpretación

El modelo alcanza un ROC AUC de 0.871, lo que indica buena capacidad para distinguir entre socios activos y socios con baja. El recall de la clase Baja es 0.467, por lo que el modelo no debe entenderse como un sistema automático perfecto, sino como una herramienta de apoyo para priorizar intervención.

Variable	Coficiente	Interpretación
Duración del contrato	-1.37	Contratos más largos se asocian con menor abandono.
Edad	-1.15	Socios de mayor edad muestran menor riesgo relativo.
Asiste a clases grupales	-0.29	La participación en clases reduce el riesgo estimado.
Viene por promoción	-0.14	La recomendación o promoción se asocia a menor abandono.
Género	0.01	Impacto prácticamente nulo en el modelo.




Figura 11. Matriz de confusión del modelo en test.

9. Conclusiones y recomendaciones

9.1 Principales hallazgos

- El abandono global de FitLife es del 26.53 %, con 1.061 bajas sobre 4.000 socios.
- El contrato mensual es el principal foco de riesgo, con 42.3 % de abandono frente a 2.4 % en contratos anuales.
- Los primeros meses son críticos: los socios nuevos presentan 42.1 % de abandono.
- Los socios de 18-25 años son el grupo más vulnerable, con 61.9 % de abandono.
- Las clases grupales reducen de forma relevante la tasa de abandono: 17.3 % con clases frente a 33.0 % sin clases.
- Los socios captados por recomendación o con vínculos sociales muestran mayor retención.

9.2 Recomendaciones accionables

Prioridad	Acción	Justificación
Alta	Programa de onboarding para socios nuevos	El abandono se concentra en los primeros 0-3 meses.
Alta	Seguimiento personalizado a socios nuevos con contrato mensual	Segmento con mayor combinación de riesgo.
Media	Incentivar clases grupales	Los asistentes a clases presentan menor abandono.
Media	Promover contratos semestrales/anuales	La duración contractual es el factor más fuerte del modelo.
Media	Campañas de referidos	Los perfiles referidos presentan mejor retención.
Baja	Comunicación periódica a socios de bajo riesgo	Mantener la fidelización sin sobreactuar.

9.3 Limitaciones

- Tres variables potencialmente útiles fueron excluidas por problemas de formato en el dataset original.
- El coste económico es una hipótesis basada en 30 EUR/mes, no una variable real del dataset.
- La regresión logística identifica asociaciones, no causalidad demostrada.
- El modelo tiene buen AUC, pero el recall de bajas indica margen de mejora si se quisiera usar en producción.
- El análisis se basa en una foto histórica de datos y no incluye evolución temporal completa por fecha.

9.4 Próximos pasos

- Incorporar datos temporales de visitas reales por semana o mes.
- Medir la efectividad de campañas de onboarding mediante test A/B.
- Reentrenar el modelo con nuevos datos y ajustar el umbral según coste de falso positivo y falso negativo.
- Conectar el dashboard a una fuente SQL actualizable para seguimiento continuo.

10. Bibliografía y referencias

- Documento Integrador del Bootcamp Data Analytics: Proyecto Integrador Final.
- Dataset: gym_churn_us.csv, incluido en el repositorio del proyecto FitLife y descargado de Kaggle
- Notebooks del proyecto: 01_exploracion_inicial, 02_limpieza_enriquecimiento, 03_analisis_exploratorio y 04_modelo_regresion_logistica.
- Scripts SQL: 01_crear_tablas.sql y 02_queries_y_kpis.sql.
- Dashboard Power BI: Proyecto_FitLife.pbix.
- Librerías utilizadas: pandas, numpy, matplotlib, seaborn y scikit-learn.